

RetailDW - Kiskereskedelmi Értékesítési Adattárház

Üzleti intelligencia labor házfeladat, amely amerikai kiskereskedelmi értékesítési adatokat tölt be egy csillag séma alapú SQL Server adat tárházba SSIS ETL pipeline segítségével, az eredményeket Power BI-ban jeleníti meg, es idősor-előrejelzést végez LSTM és GRU neurális hálózattal egy Jupyter notebookban.

RENDSZERKOVETELMENYEK

A projekt futtatásához az alábbiakra van szükség:

- SQL Server (LocalDB vagy Express kiadás) szükséges adatbázismotorként. A projekt a (localdb)\MSSQLLocalDB nevű helyi példányhoz csatlakozik. (opcionális) SQL Server Management Studio az adatok ellenőrzéséhez.
- Visual Studio 2019 vagy újabb verzió a SQL Server Integration Services Projects bővítménnyel szükséges az SSIS csomagok megnyitásához, szerkesztéséhez és fordításához. A lefordított csomag (RetailDW_ETL.ispac) már szerepel a projektben, ezért Visual Studio. csak akkor szükséges, ha a csomagokat módosítani szeretnénk.
- Power BI Desktop szükséges a riportfájl megnyitásához.
- Python 3.x szükséges a Jupyter notebookhoz. A következő csomagokat kell telepíteni: pandas, numpy, matplotlib, scikit-learn és tensorflow.

PROJEKTSTRUKTÚRA

A projekt gyökérkönyvtára a következő fájlokat és mappákat tartalmazza:

A run_ssis.bat egy batch szkript, amely az egész ETL pipeline-t futtatja. Duplán kattintva rá, vagy terminálból indítva végrehajtja a Master SSIS csomagot, amely betölti az összes adatot és feltölti az adatbázist.

A reset_database.sql egy SQL szkript, amely törli az összes adatot az adatbázisból, majd újra feltölti a dátum dimenziót 2014-től 2018-ig terjedő dátumokkal. SSMS-ben kell futtatni, ha tiszta lappal szeretnénk kezdeni.

Az etl_log.txt fájlt a run_ssis.bat automatikusan hozza létre és frissíti minden futtatáskor. Tartalmazza az egyes futások dátumát, időpontját és eredményét.

A **data** mappa tartalmazza az összes adatforrást. A raw almappában található a két eredeti forrásfájl: a "Sample - Superstore.csv" a fő kiskereskedelmi értékesítési adathalmaz körülbelül 10 000 sorral, valamint az "US Holiday Dates (2004-2021).csv", amely az USA állami ünnepnapjait tartalmazza, és a dátum dimenzió gazdagítására szolgál. A split almappában az értékesítési adatok négy egyenlő részre osztva találhatóak, sales_chunk_1.csv-től sales_chunk_4.csv-ig. Ezeket az ETL pipeline egymás után tölti be. A split.py egy Python szkript, amellyel ezeket a fájlokat az eredeti forrásból létrehoztuk.

Az **ssis** mappa tartalmazza a Visual Studio megoldást. A megoldásfájl neve RetailDW_ETL.slnx, és közvetlenül megnyitható Visual Studióban. A projekten belül hat SSIS csomag található: a Master.dtsx az egész pipeline-t koordinálja és sorban meghívja az összes többi csomagot

- LoadHolidayDimension.dtsx betölti az ünnepnap-referenciaadatokat
- LoadSalesChunk.dtsx egy CSV-fájlt tölt be a staging táblába
- TransformToFact.dtsx a staging adatokat áthelyezi a ténytáblába és a dimenziókba
- AggregateMonthly.dtsx újraépíti a havi összesítő táblát
- AggregateCategory.dtsx újraépíti a kategória összesítő táblát.

A **reports** mappa tartalmazza a RetailDW_reports.pbix Power BI riportfájlt.

A **notebooks** mappa tartalmazza a sales_forecasting.ipynb Jupyter notebookot.

A **docs** mappa kiegészítő dokumentumokat tartalmaz, köztük ezt a fájlt.

Az **sql** mappa tartalmaz adatbázis építő scripteket.

ADATBÁZIS-STRUKTÚRA

Az adatbázis neve RetailDW, és a (localdb)\MSSQLLocalDB SQL Server példányon fut. Csillagsémát használ, amelynek középpontjában egy ténytábla áll, amelyhez három dimenziótábla, két előre számított összesítő tábla és egy staging tábla kapcsolódik.

A **dim_time** dimenziótábla 2014. január 1-jétől 2018. december 31-ig minden napra tartalmaz egy sort, összesen 2557 sort. Minden sor tárolja a dátumkulcsot (egy egész szám yyyyMMdd formátumban), a teljes dátumot, az évet, a hónapot, a hétszámot, a hét napját, a nap nevét, a hónap nevét, valamint egy jelzőt, amely mutatja, hogy az adott nap ünnepnap-e.

A **dim_holiday** dimenziótábla 342 sort tartalmaz az USA állami ünnepnapjairól. Minden sor tárolja az ünnepnap dátumát, nevét, a hét napját, a hónapot, a napot és az évet.

A **dim_category** dimenziótábla 17 sort tartalmaz, amelyek az értékesítési adatokban szereplő egyedi termékkategória és alkategória kombinációkat képviselik.

A **fact_sales** ténytábla a központi ténytábla 9994 sorral. Minden sor egy értékesítési tranzakciót képvisel, és tárolja a rendelésazonosítót, a dátumkulcsot, a kategória kulcsot, a vásárlóazonosítót, a vásárlói szegmenst, a várost, az államot, a régiót, az értékesítési összeget, a mennyiséget, az engedményt, a profitot és egy ünnepnap jelzőt.

Az **agg_monthly_sales** tábla egy előre számított összesítés 573 sorral, amely év, hónap, régió és kategória szerint csoportosítja az értékesítéseket, és tartalmazza a teljes értékesítést, teljes profitot és rendelésszámot.

Az **agg_category_sales** tábla egy előre számított összesítés 17 sorral, amely kategória és alkategória szerint csoportosítja az értékesítéseket, és tartalmazza a teljes értékesítést, teljes profitot, átlagos engedményt és teljes mennyiséget.

A **staging_sales** tábla egy ideiglenes tárolóterület a nyers CSV-adatok számára az ETL folyamat során. Az ETL lefutása után mindig üres.

ETL PIPELINE

Az ETL pipeline hat SSIS csomagból áll, amelyeket a Master.dtsx koordinál. Az első lépés törli a staging táblát, hogy az előző futás esetleges maradék adatai ne zavarják az aktuális futást.

A második lépés betölti az ünnepnap dimenziót. A LoadHolidayDimension.dtsx közvetlenül olvassa az "US Holiday Dates (2004-2021).csv" fájlt. A fájl vesszővel tagolt, és egyes ünnepnevekben vesszők szerepelnek (például "Martin Luther King, Jr. Day"), amelyeket a flat file kapcsolatkezelőben beállított idézőjel szövegelhatároló kezel. A csomag minden futáskor truncate-eli és teljesen újratölti a dim_holiday táblát.

A harmadik lépés egy ciklus, amely végigmegy az összes sales_chunk_*.csv fájlra a split mappában. Minden fájl esetén a LoadSalesChunk.dtsx beolvassa a fájlt és betölti a staging_sales táblába, majd a TransformToFact.dtsx négy SQL műveletet hajt végre: beilleszti az új kategória és alkategória kombinációkat a dim_category táblába, frissíti az IsHoliday jelzőt a dim_time táblában a dim_holiday táblával való összekapcsolás alapján, beilleszti az átalakított sorokat a fact_sales táblába egy WHERE NOT EXISTS ellenőrzéssel a duplikátumok megelőzésére, végül pedig truncate-eli a staging táblát.

A negyedik és ötödik lépés újraépíti a két összesítő táblát. Az AggregateMonthly.dtsx truncate-eli és újraépíti az agg_monthly_sales táblát a teljes fact_sales tábla alapján. Az AggregateCategory.dtsx ugyanezt teszi az agg_category_sales táblával.

Minden csomag idempotens, vagyis a pipeline többször is futtatható duplikált vagy inkonzisztens adatok létrehozása nélkül.

FUTTATÁS

1. lépés - Adatbázis előkészítése

Nyissa meg az SSMS-t, és csatlakozzon a (localdb)\MSSQLLocalDB példányhoz. Ha a RetailDW adatbázis még nem létezik, hozza létre és futtassa a táblalétrehozó szkripteket. Ha az adatbázis már akkor kell lefuttatni a reset_database.sql fájlt. Ez törli az összes adatot az összes táblából, és újra feltölti a dim_time táblát 2014-től 2018-ig terjedő dátumokkal.

2. lépés - ETL futtatása

Duplán kattintson a run_ssis.bat fájlra a Fájlkezelőben, vagy futtassa terminálból. A szkript a dtexec segítségével végrehajtja a Master SSIS csomagot és az eredményt rögzíti az etl_log.txt fájlban. A teljes pipeline néhány másodperc alatt lefut.

3. lépés - Ellenőrzés SSMS-ben

Az ETL lefutása után az alábbi lekérdezésekkel ellenőrizheti az eredményeket:

```
USE RetailDW;
```

```
SELECT COUNT(*) FROM fact_sales;    -- várt eredmény: 9994
```

```
SELECT COUNT(*) FROM dim_holiday;   -- várt eredmény: 342
```

```
SELECT COUNT(*) FROM dim_category;  -- várt eredmény: 17
```

```
SELECT COUNT(*) FROM agg_monthly_sales; -- várt eredmény: 573
```

4. lépés - Power BI riport megnyitása

Nyissa meg a reports/RetailDW_reports.pbix fájlt a Power BI Desktopban. A riport csatlakozik a RetailDW adatbázishoz és négy oldalt tartalmaz.

- A Dashboard oldal KPI kártyákat mutat a teljes bevételről, profitról és rendelésszámról, valamint egy kategória szerinti bontást.
- Az Holiday Analysis oldal összehasonlítja az ünnepnapokon és a többi napon mért értékesítéseket.
- A Top Products oldal alkategóriák szerint rangsorolja a termékeket értékesítés és profit alapján.
- A Monthly Trends oldal egy havi értékesítési idősort mutat, amelyen jól látható a szezonális minta.

Megjegyzés: a LocalDB dinamikus named pipe-ot használ a kapcsolathoz. Ha a Power BI nem tud csatlakozni az alapértelmezett server névvel, futtassa az "sqllocaldb info MSSQLLocalDB" parancsot egy terminálban, és használja az ott megjelenő named pipe címet np:\\.\pipe\LOCALDB#XXXXXXXXX\tsql\query formátumban.

5. lépés - Jupyter notebook futtatása

Jupyter notebookot érdemes Google Colab-ba feltölteni hogy a függőségeket ne kelljen beállítani localban.

A sales_forecasting.ipynb fájlt kell megnyitni a Jupyterben. A notebook automatikusan megkeresi és betölti az összes elérhető sales_chunk_*.csv fájlt a data/split mappából, ezért működik akkor is, ha csak néhány chunk áll rendelkezésre.

A notebook hét részből áll. Az első rész betölti az adatokat és feltáró elemzést végez, beleértve az eloszlás vizualizálását, trendek bemutatását és a hét napja szerinti mintázatok vizsgálatát. A második rész ciklikus időbeli jellemzőket von ki szinusz és koszinusz transzformációkkal, hogy helyesen kódolja a hét napjának és az év napjának periodikus jellegét. A harmadik és negyedik rész StandardScaler segítségével skálázza az adatokat, majd időalapú felosztással létrehozza a tanító (2014-2015), validációs (2016) és teszt (2017) halmazokat az adatszivárgás megakadályozása érdekében. Az ötödik rész LSTM modelleket tanít heti összesített és hétnapos gördülő átlag adatokon. A hatodik rész egyenértékű GRU modelleket tanít. A hetedik rész MSE, RMSE és MAE metrikákkal összehasonlítja mind a négy modellt és vizualizálja az eredményeket. A legjobb modell a gördülő átlag adatokon tanított GRU, amelynek MSE értéke körülbelül 255 785.

VISSZAÁLLÍTÁS ÉS ÚJRAFUTTATÁS

A teljes pipeline elejéről való demózásához futtassa a reset_database.sql szkriptet SSMS-ben, majd futtassa a run_ssis.bat fájlt, végül frissítse a Power BI riportot a Kezdőlap menü Frissítés gombjával.

ADATFORRÁSOK

A Superstore Sales adathalmaz a Kaggle platformról származik (<https://www.kaggle.com/datasets/vivek468/superstore-dataset-final>), és körülbelül 10 000 kiskereskedelmi rendelést tartalmaz 2014-től 2018-ig az Egyesült Államokból.

Az USA állami ünnepnapok adathalmaz is szintén a Kaggle platformról származik (<https://www.kaggle.com/datasets/donnetew/us-holiday-dates-2004-2021>), és 342 szövetségi és állami ünnepnapot tartalmaz 2004-től 2021-ig.

LINKEK

Repo: <https://github.com/Fly1ngSpaghettiMonster/BILNHF>

Demo Video: <https://youtu.be/r9KNfEVV2b8>