

Félévi NagyHF specifikáció

Üzleti Intelligencia Labor

Félév: 2026 tavasz

Kiskereskedelmi Értékesítés Intelligencia

Reisz Balázs Dávid - (XIVSHH)

reisz.balazs@edu.bme.hu



Bemutató

A félévi nagy házi feladat célja egy kiskereskedelmi értékesítési adatokat feldolgozó üzleti intelligencia megoldás elkészítése. A rendszer két adatforrásból dolgozik: az elsődleges adatforrás a Kaggle-ről származó Superstore Sales adathalmaz (~10 000 rendelés, amely tartalmazza a rendelések dátumát, vásárlói szegmenst, régiót, államot, termékkategóriát, eladási összeget, mennyiséget, kedvezményt és profitot), a másodlagos adatforrás pedig az USA ünnepnapok naptára (US Public Holidays), amely dimenzióként gazdagítja az értékesítési adatokat szezonális információkkal (ünnepnap vs. hétköznapi eladások összehasonlítása).

A fő KPI-k az összesített árbevétel, profit, rendelésszám, átlagos rendelési érték, valamint a profit/árbevétel arány, melyek régió, kategória és időszak szerint bontva jelennek meg. A reportok PowerBI-ban készülnek, interaktív szűréssel, rendezéssel és lefűrási lehetőségekkel (regió → állam → város). Az adatelemzés/data science rész egy Jupyter notebook-ban valósul meg, amely pandas-alapú feltáró elemzést (EDA), majd LSTM és GRU neurális hálózatokkal történő idősor-előrejelzést tartalmaz a napi értékesítési összeg predikciójára.

Adatforrások

[Superstore Sales Dataset](#) ~10 000 sor, CSV formátum. Az adatforrás 4 darab CSV fájlra lesz felvágva (~2 500 sor/fájl), így szimulálható az inkrementális betöltés

[US Public Holidays](#) USA szövetségi és egyéb ünnepnapok dátumai és megnevezései. Dimenzióként szolgál az értékesítési adatok szezonális elemzéséhez (ünnepnap vs. nem-ünnepnap eladások)

Főbb funkciók

Az adattárolás Microsoft SQL Server (localdb/Express) környezetben valósul meg egy RetailDW nevű adatbázisban. A rendszer több rétegből áll: egy staging réteg (staging_sales), amely a nyers CSV adatokat fogadja; dimenzió táblák (dim_holiday, dim_category, dim_time), amelyek a leíró adatokat tartalmazzák; egy ténytábla (fact_sales), amely a tisztított és összekapcsolt értékesítési adatokat tárolja; valamint aggregált táblák (agg_monthly_sales, agg_category_sales), amelyek előre számolt összesítéseket biztosítanak.

Az adatfeldolgozás ETL folyamatokon keresztül történik. A folyamat első lépése a CSV fájlok betöltése a staging táblába (Load Sales Chunk), majd az ünnepnapokat tartalmazó dimenzió feltöltése (Load Holiday Dimension). Ezt követi a staging adatok tisztítása és átalakítása a ténytáblába (Transform to Fact), amely során duplikátum szűrés, típuskonverzió és dimenzió kulcsok hozzárendelése történik. Végül aggregációs lépések készülnek: havi szintű összesítések (Aggregate Monthly), valamint kategória alapú összesítések (Aggregate Category).

Az ETL folyamatok futtatása SQL Server Agent segítségével történik, demo célokra percenkénti ütemezéssel. Az első néhány futás során a CSV fájlok részletekben betöltődnek, majd a transzformációs és aggregációs lépések lefutnak. Ennek eredményeként az adatok folyamatosan frissülni fognak.

Az elemzésre kész adatok a fact_sales, agg_monthly_sales és agg_category_sales táblákban találhatók, amelyekhez a dimenzió táblák kapcsolódnak. Ezek az adatok szolgálnak alapul a megjelenítési és elemzési réteg számára.

A megjelenítési réteg PowerBI reportokból áll, amelyek különböző nézetekben mutatják be az adatokat. Tartalmaznak egy általános értékesítési dashboardot KPI mutatókkal, egy ünnepnapi elemzést az értékesítések összehasonlítására, egy top termékeket bemutató nézetet, valamint havi trendeket ábrázoló grafikont. A reportok támogatják a szűrést, szeletelést és lefűrást.

Az adatelemzési (data science) rész Python alapú Jupyter Notebook környezetben valósul meg. Ez magában foglalja az adatok feltárási elemzését (EDA), időbeli jellemzők kinyerését, az adatok skálázását, valamint időalapú tanító, validációs és teszt halmazok kialakítását. A predikciós feladat megoldására LSTM és GRU neurális hálózatok kerülnek alkalmazásra Keras segítségével, a modellek teljesítményét pedig vizualizációkkal értékeljük.

Választott technológiák

- Microsoft SQL Server (localdb / Express): adatbázis (RetailDW)
- SQL Server Integration Services (SSIS): ETL folyamatok
- SQL Server Agent: ütemezés
- PowerBI Desktop: riportok és dashboardok
- Jupyter Notebook: fejlesztési környezet
- pandas:adatkezelés, EDA
- matplotlib: vizualizáció
- TensorFlow / Keras : neurális hálók (LSTM, GRU)
- NumPy: numerikus számítások